Sampling Theory and Hypothesis Testing

TS. Lưu Phúc Lợi
Trưởng phòng Nghiên cứu khoa học
Viện ARiHA

Các loại thống kê

Thống kê suy luận

- Ước lượng tham số
  - Ước lượng tham số cho tổng thể
- Kiểm định giả thuyết
  - Kiểm định so sánh (comparison test)
  - Phân tích mối tương quan (correlation analysis)
  - Phân tích hồi quy (regression analysis)

1. Định lý giới hạn trung tâm

Central Limit Theorem - CLT

"*Dưới các điều kiện thích hợp thì một phân phối xác suất khi được chuẩn hóa của trung bình mẫu sẽ hội tụ đến phân phối chuẩn tắc, dù phân phối ban đầu có thể không chuẩn.*"

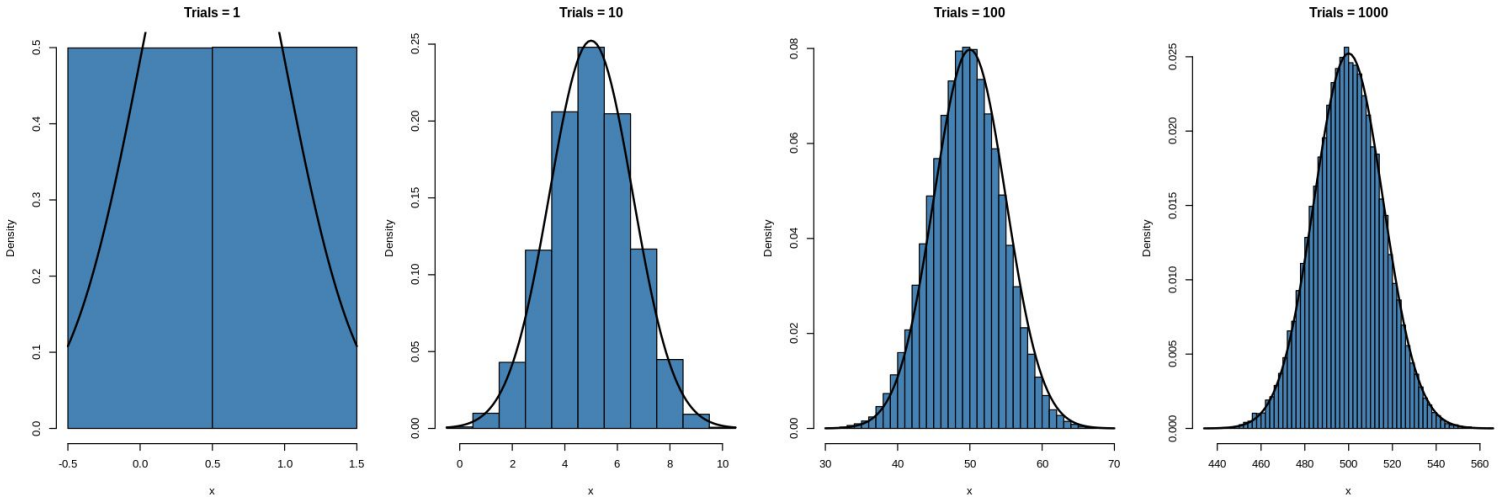

Pólya, G. (1920). Über den zentralen Grenzwertsatz der Wahrscheinlichkeitsrechnung und das Momentenproblem. *Mathematische Zeitschrift, 8*, 171–181. https://doi.org/10.1007/BF01206525

2. Xác suất trung bình của mẫu

Sampling distribution of the mean

*Nếu ta lấy rất nhiều mẫu kích thước **n** từ cùng một quần thể, mỗi mẫu cho ra một trung bình. Tập hợp các trung bình đó tạo thành một phân phối.*

*Khi **n** tăng, trung bình mẫu có xu hướng tiến gần μ (trung bình thật của quần thể).*

Thống kê suy luận dùng phân phối này để ước lượng μ và định lượng độ không chắc chắn (SE, CI, p-value).

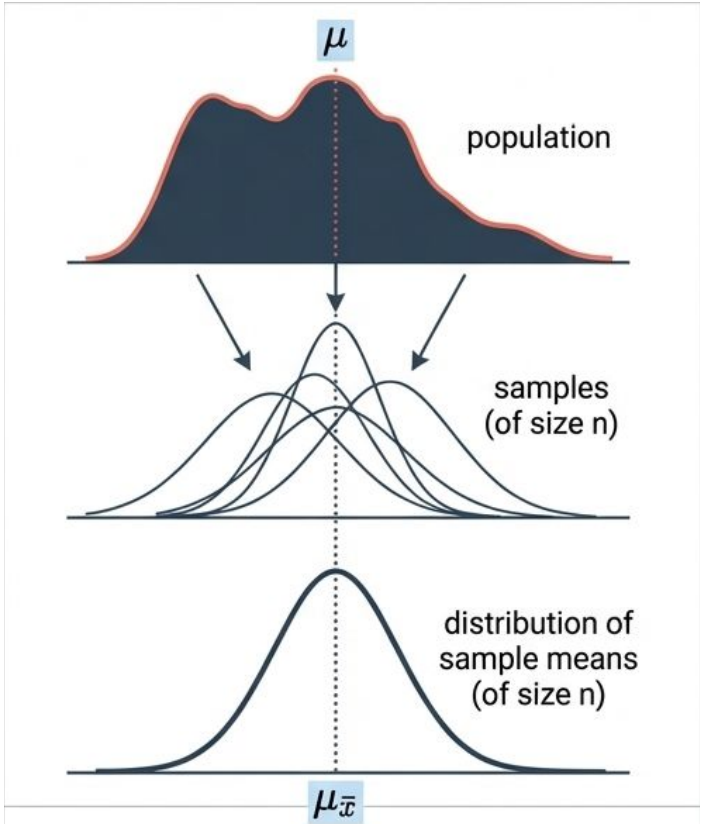

Bernoulli, J. (1713). *Ars Conjectandi*. Basel: Thurnisius.

Thế nào là phân phối chuẩn?

Phân phối chuẩn (normal distribution) là một phân bố xác suất liên tục có hình chuông đối xứng, tập trung quanh giá trị trung bình (μ).

Đặc điểm:

- Mean (μ)
- Độ lệch chuẩn (σ)

Quy tắc 68–95–99.7:

- 68% giá trị nằm trong **μ±1σ**
- 95% nằm trong **μ±2σ**
- 99.7% trong **μ±3σ**

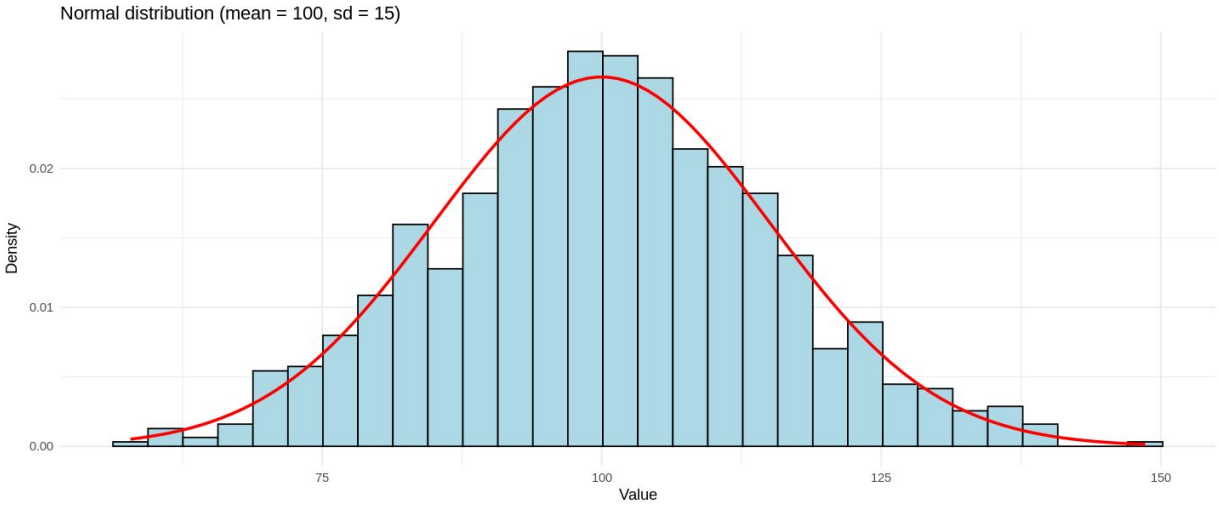

Gauss, C. F. (1809). *Theoria motus corporum coelestium in sectionibus conicis solem ambientium*. Hamburg: Sumptibus F. Perthes et I. H. Besser.

Ma trận Sai số (Type I & Type II Errors)

		Sự thật ngoài đời	
		H0 Đúng (Không có tác dụng)	H0 Sai (Có tác dụng thật)
Quyết định của ta	Giữ H0	**Đúng đắn** (1 - α)	**Sai lầm Loại II** (β - False Negative) VD: Thuốc có tác dụng nhưng kết luận là không.
	Bác bỏ H0	**Sai lầm Loại I** (α - False Positive) VD: Thuốc không có tác dụng nhưng kết luận là có.	**Độ nhạy (Power)** (1 - β)

1. Ý nghĩa thống kê

p value

***H_0**: Giả thuyết không có khác biệt*
(mọi sai khác quan sát được trong mẫu chỉ do ngẫu nhiên/lấy mẫu và sai số đo chứ không phản ánh khác biệt thật ở quần thể)

- Ý nghĩa thống kê dưới dạng **$p < \alpha$ (0,05)**

- Vì **$p < \alpha$** nên kết quả quan sát có ít hơn 5% giả định **H_0** đúng, ta nói kết quả có ý nghĩa thống kê và thường bác bỏ **H_0** => có sự khác biệt giữa hai nhóm nghiên cứu

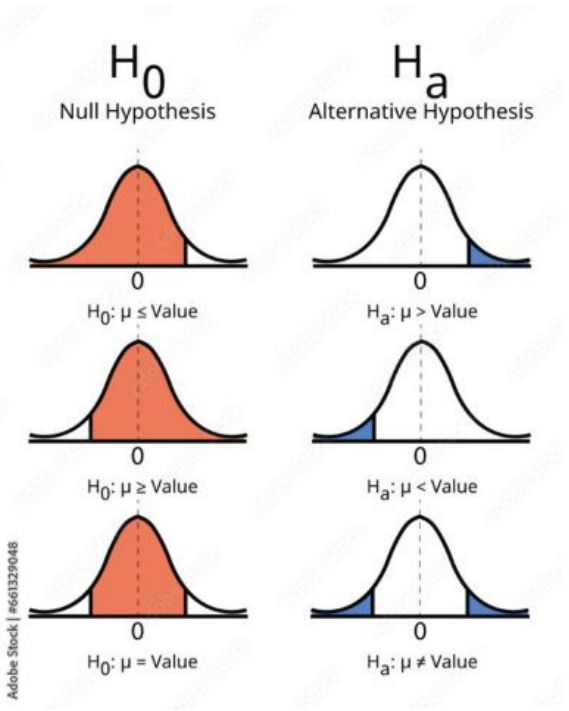

Pearson, K. (1900). On the criterion that a given system of deviations from the probable in the case of a correlated system of variables is such that it can be reasonably supposed to have arisen from random sampling. *The London, Edinburgh, and Dublin Philosophical Magazine and Journal of Science*, Series 5, *50*(302), 157–175. https://doi.org/10.1080/14786440009463897

Fisher, R. A. (1958). *Statistical methods for research workers* (13th rev. ed.). Hafner Publishing Company.

Ý nghĩa thống kê *(p-value)*

p nhỏ → dữ liệu **khó xảy ra** nếu H0 đúng → bằng chứng chống lại H0 mạnh hơn.

p lớn → dữ liệu chi thấy H0 xảy ra cao hơn → chưa có bằng chứng để bác bỏ H0.

Thống kê mô tả

Nhập liệu (Import): Đọc file .csv vào biến df.

Làm sạch (Clean): Biến đổi dữ liệu bất thường (VD: Cholesterol = 0 thành NA).

Gán nhãn (Factorize): Chuyển (0/1) thành (No/Yes).

Age	Sex	ChestPainType	RestingBP	Cholesterol	FastingBS	RestingECG	MaxHR	ExerciseAngina	Oldpeak	ST_Sope	HeartDisease
<int>	<chr>	<chr>	<chr>	<int>	<int>	<chr>	<int>	<chr>	<dbl>	<chr>	<int>
40	M	ATA	140	289	0	Normal	172	N	0.0	Up	0
49	F	NAP	160	180	0	Normal	156	N	1.0	Flat	1
37	M	ATA	130	283	0	ST	98	N	0.0	Up	0
48	F	ASY	138	214	0	Normal	108	Y	1.5	Flat	1
54	M	NAP	150	195	0	Normal	122	N	0.0	Up	0
39	M	NAP	120	339	0	Normal	170	N	0.0	Up	0
39	M	NAP	120	339	0	Normal	170	N	0.0	Up	0
45	F	ATA	130	237	0	Normal	170	N	0.0	Up	0
54	M	ATA	110	208	0	Normal	142	N	0.0	Up	0

```
> df <- read.csv('/content/Heart_Data.csv')
> df$HeartDisease <- factor(df$HeartDisease,
levels=c(0,1), labels=c('No', 'Yes'))
```

Bệnh nhân: Bộ dữ liệu Heart Failure Prediction (918 mẫu, 12 biến số lâm sàng).

Thống kê mô tả

	Stratified by HeartDisease			
	Overall	No	Yes	p
n	918	410	508	
Age (mean (SD))	53.5 (9.4)	50.6 (9.4)	55.9 (8.7)	<0.001
Sex = Female (%)	193 (21.0)	143 (34.9)	50 (9.8)	0.001
RestingBP (mean (SD))	132.4 (18.5)	130.2 (16.5)	134.2 (19.8)	0.001
Cholesterol (mean (SD))	244.6 (59.2)	238.8 (55.4)	251.1 (62.5)	0.005
FastingBS = > 120 mg/dl (%)	214 (23.3)	44 (10.7)	170 (33.5)	<0.001

	Stratified by HeartDisease
	test Missing
n	
Age (mean (SD))	0.0
Sex = Female (%)	0.0
RestingBP (mean (SD))	0.0
Cholesterol (mean (SD))	18.7
FastingBS = > 120 mg/dl (%)	0.0

Kiểm định tự động

Insight: Trả lời câu hỏi "Mẫu nghiên cứu trông như thế nào trước khi phân tích sâu?" - Phân tầng theo biến Outcome (HeartDisease).

```r
library(table1)

table1(~
  Age + Sex +
  RestingBP + Cholesterol
  + FastingBS |
  HeartDisease, data=df)
```

Lựa chọn phép kiểm định phù hợp

Biến phụ thuộc

1. Biến phụ thuộc là biến liên tục

- Nếu X là 2 nhóm → independent t-test (hoặc paired t-test)
- Nếu X là ≥3 nhóm → ANOVA

2. Biến phụ thuộc phân loại/nhị phân

- Nếu X cũng phân loại → Chi-square độc lập

Lựa chọn phép kiểm định phù hợp

Biến độc lập là kiểu phân loại hay liên tục?

1. Biến độc lập là kiểu phân loại: nhóm (Sex, nhóm tuổi, ChestPainType…) → t-test/ANOVA/Chi-square

2. Biến độc lập là kiểu liên tục: tuổi, cholesterol… → thường là correlation/regression.

1.1. T-test

Kiểm định sự khác biệt trung bình (mean) của một biến định lượng giữa hai điều kiện/nhóm.

- One-sample t-test: so sánh mean mẫu với một giá trị chuẩn μ_0.
- Independent two-sample t-test: so sánh mean giữa 2 nhóm độc lập (Group A vs Group B).
- Paired t-test: so sánh mean của chênh lệch trong thiết kế cặp đôi/ trước–sau (cùng đối tượng đo 2 lần).

Ví dụ:

```
df <- read.csv("/content/Heart_Data.csv")
df$Cholesterol[df$Cholesterol=0] <- NA
t.test(Cholesterol ~ HeartDisease, data=df)$p.value
```

> 0.00474182506868301

Diễn giải: “So sánh nồng độ cholesterol huyết thanh giữa nhóm có bệnh tim và nhóm không có bệnh tim bằng kiểm định t độc lập (Welch). Kết quả cho thấy có sự khác biệt có ý nghĩa thống kê về giá trị trung bình cholesterol giữa hai nhóm (p = 0.0047)”

Diễn giải thống kê (ý nghĩa p-value)

Bạn đã thực hiện **kiểm định t hai mẫu độc lập** để so sánh **trung bình Cholesterol** giữa hai nhóm theo biến `HeartDisease` (có/không bệnh tim). Trong R, `t.test(y ~ group)` mặc định là **Welch’s t-test** (không giả định phương sai hai nhóm bằng nhau).

- **Giả thuyết không (H0):** Trung bình Cholesterol ở hai nhóm `HeartDisease` là **bằng nhau**.
- **Giả thuyết đối (H1):** Trung bình Cholesterol ở hai nhóm là **khác nhau** (kiểm định hai phía).

Với **p-value = 0.00474**, nếu chọn mức ý nghĩa thường dùng **α = 0.05** (thậm chí α = 0.01), ta có:

- **Bác bỏ H0**.
- Có **bằng chứng thống kê** cho thấy **trung bình Cholesterol khác nhau** giữa hai nhóm `HeartDisease`.

Diễn giải đúng của p-value:

> Nếu trong thực tế **không có khác biệt trung bình** Cholesterol giữa hai nhóm, thì xác suất quan sát được (hoặc quan sát được kết quả “cực đoan hơn”) như dữ liệu hiện tại chỉ khoảng **0.47%**.

Hạn chế

- Không cho biết mức độ khác nhau/tương quan
- Không cho biết độ chính xác của ước lượng
- Giá trị phụ thuộc vào cỡ mẫu

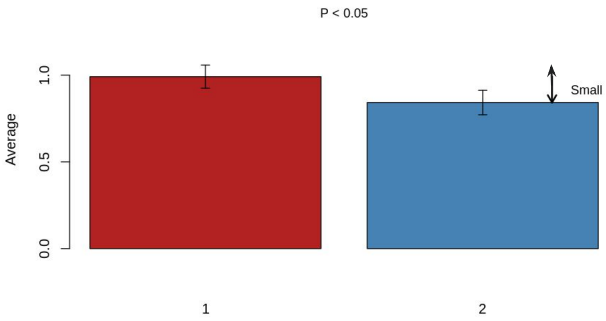

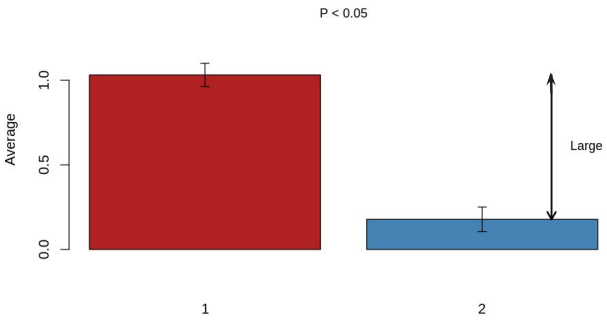

Pearson, K. (1900). On the criterion that a given system of deviations from the probable in the case of a correlated system of variables is such that it can be reasonably supposed to have arisen from random sampling. *The London, Edinburgh, and Dublin Philosophical Magazine and Journal of Science*, Series 5, *50*(302), 157–175. https://doi.org/10.1080/14786440009463897

Fisher, R. A. (1958). *Statistical methods for research workers* (13th rev. ed.). Hafner Publishing Company.

2. Hệ số ảnh hưởng

2.1. Cohen's d - d

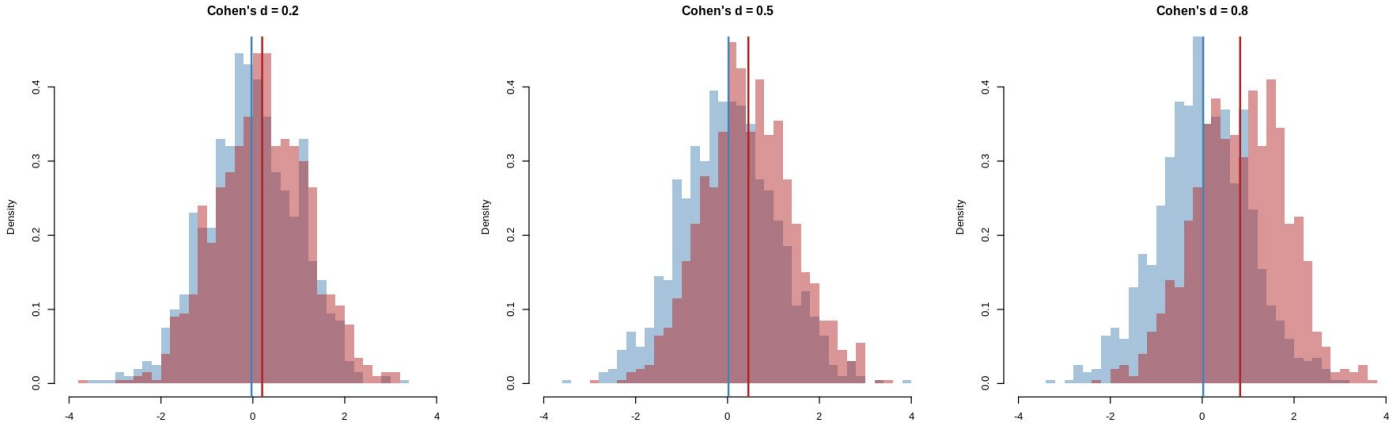

Cohen's d là một chỉ số thống kê dùng để đo mức độ khác biệt giữa hai nhóm theo đơn vị độ lệch chuẩn

$$d = \frac{\bar{x}_1 - \bar{x}_2}{s_p} \qquad s_p = \sqrt{\frac{(n_1 - 1)s_1^2 + (n_2 - 1)s_2^2}{n_1 + n_2 - 2}}$$

Sp là độ lệch chuẩn gộp (pooled SD)

2.1. Cohen's d

Ví dụ: Tính hệ số d giữa biến Age và biến bệnh suy tim (HeartDisease)

```
df <- read.csv("/content/Heart_Data.csv")
df$HeartDisease <- factor(df$HeartDisease, levels = c(0,1), labels = c("Khong","Co"))
age1 <- df$Age[df$HeartDisease =="Khong"]
age2 <- df$Age[df$HeartDisease =="Co"]
x1 <- mean(age1)
x2 <- mean(age2)
s1 <- sd(age1)
s2 <- sd(age2)
sp <- sqrt( ((length(age1) - 1)*s1^2 + (length(age2) - 1)*s2^2) / (length(df$Age)- 2) )
d <- (x2 - x1) / sp
```

$$d = \frac{\bar{x}_1 - \bar{x}_2}{s_p} \qquad s_p = \sqrt{\frac{(n_1 - 1)s_1^2 + (n_2 - 1)s_2^2}{n_1 + n_2 - 2}}$$

```
> n1 (Khong) = 410
> n2 (Co)    = 508
> x1 = 50.55122
> x2 = 55.89961
> s1 = 9.444915
> s2 = 8.727056
> sp = 9.05462
> d  = 0.5906804
```

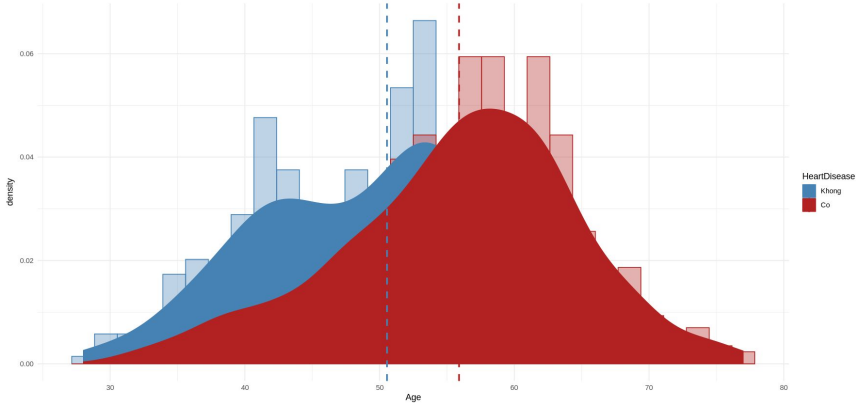

2.1. Cohen's d

Ví dụ: Tính hệ số d giữa biến Age và biến bệnh suy tim (HeartDisease)

Package: lsr

```
library(lsr)
heart = read.csv("/content/Heart_Data.csv")
cohensD(formula = Age ~ HeartDisease, data = heart)
> 0.590680436457599
```

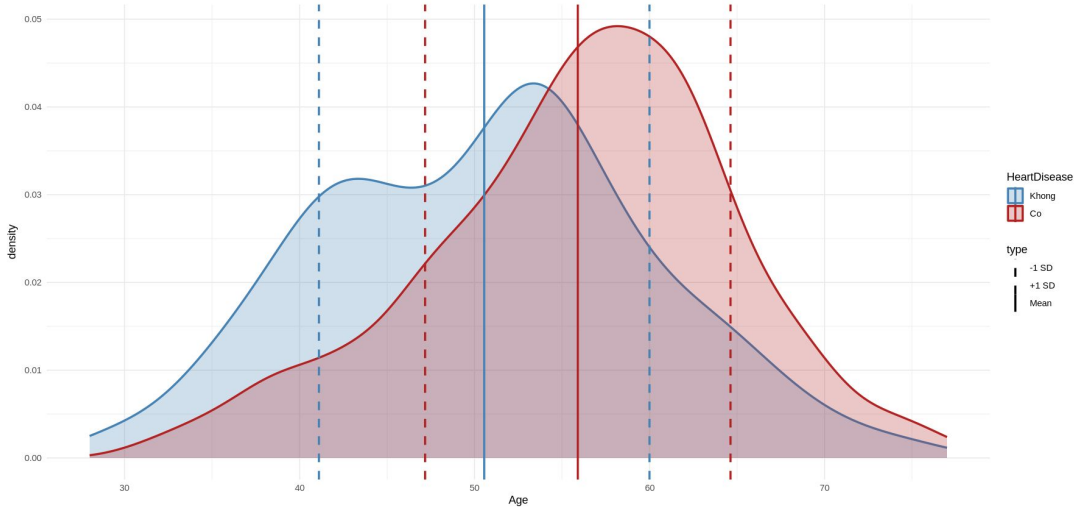

2.2. Pearson correlation

(r)

Hệ số đo mức độ và chiều hướng liên hệ tuyến tính giữa hai biến định lượng X và Y. Về bản chất, nó là hiệp phương sai được chuẩn hoá theo độ lệch chuẩn của từng biến, nên không có đơn vị đo và nằm trong khoảng [−1, 1]:

- **r = 1**: tuyến tính dương hoàn hảo
- **r = −1**: tuyến tính âm hoàn hảo
- **r = 0**: không có liên hệ tuyến tính

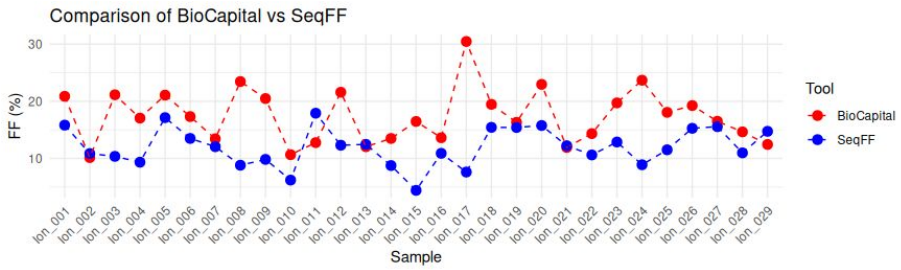

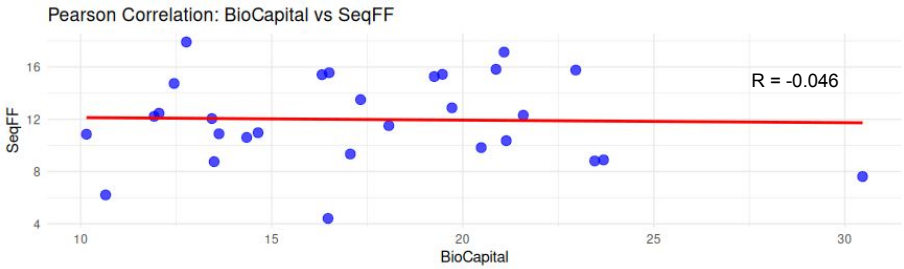

Pearson, K. (1896). *Mathematical contributions to the theory of evolution—III. Regression, heredity, and panmixia*. *Philosophical Transactions of the Royal Society of London. Series A*, *187*, 253–318. https://doi.org/10.1098/rsta.1896.0007

Pearson correlation - *r*

Ví dụ: Tính hệ số r giữa biến Age và biến Cholesterol

```
df <- read.csv("/content/Heart_Data.csv")
df$Cholesterol[df$Cholesterol == 0] <- NA
##fuction cor()
r <- cor(df$Age, df$Cholesterol, method = "pearson", use = "complete.obs")
cat("Pearson r =", r, "\n")
```

```
> Pearson r = 0.05875824
```

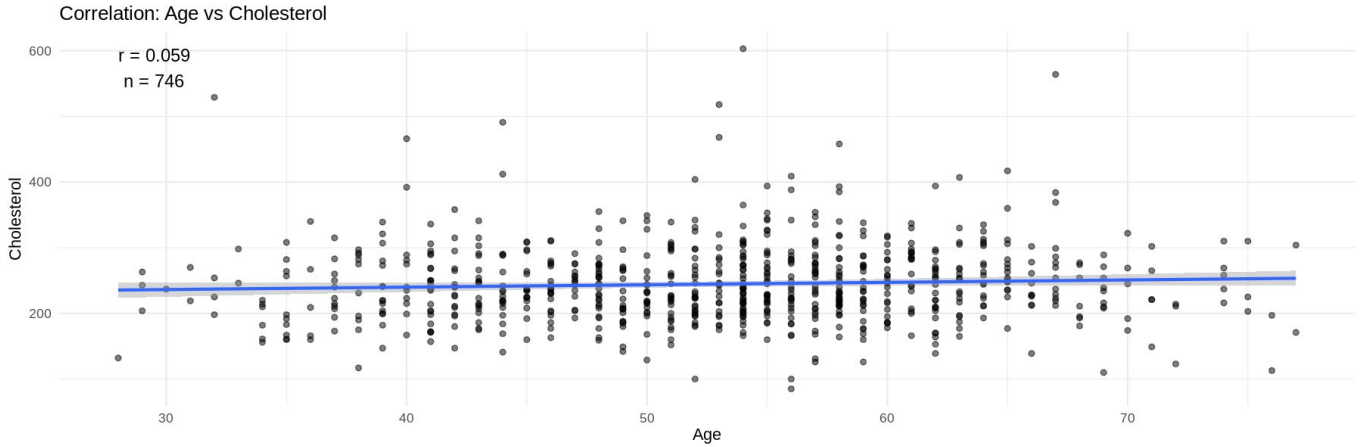

Hạn chế

- Ảnh hưởng bởi outlier và phân phối lệch
- Không cho biết khác/giống nhau có ý nghĩa thống kê hay không
- **r** cao không đảm bảo dự đoán chính xác theo nghĩa lâm sàng; cần xem thêm hồi quy, RMSE, …

Giữ giá trị Cholesterol = 0
d = -0.481
Bỏ giá trị Cholesterol = 0 (NA)
d = 0.209
Số Cholesterol = 0 theo nhóm
0=No: 20
1=Yes: 152

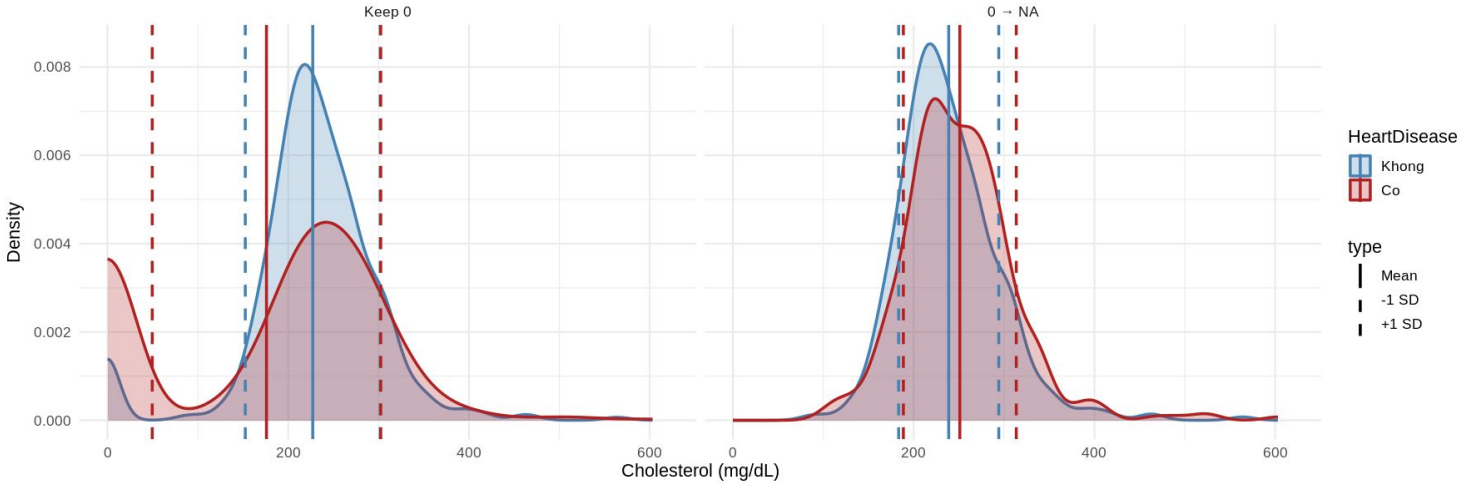

3. Khoảng tin cậy

Neyman (1937) là người đưa ra khung lý thuyết “confidence limits / confidence coefficient / confidence interval”: ông định nghĩa **confidence limits** là hai hàm của dữ liệu và **confidence coefficient** là xác suất bao phủ (coverage) của thủ tục đó; khoảng giữa 2 giới hạn là **confidence interval**.

“Tham số thật là hằng số, còn khoảng CI là biến ngẫu nhiên; vì vậy sau khi tính xong CI, việc “tham số nằm trong khoảng hay không” (với khoảng vừa tính) về mặt logic là 0 hoặc 1, không phải “95%””

Neyman, J. (1937). Outline of a theory of statistical estimation based on the classical theory of probability. *Philosophical Transactions of the Royal Society of London. Series A, Mathematical and Physical Sciences, 236*(767), 333–380. https://doi.org/10.1098/rsta.1937.0005

3. Khoảng tin cậy

Confidence interval - CI

Là khoảng mà trung bình của các mẫu lấy ra từ tổng thể sẽ nằm trong khoảng đó (với độ tin cậy nhất định, thường chọn 95%)

Nếu lặp lại việc lấy mẫu nhiều lần, 95% các khoảng CI này sẽ chứa tham số thực của quần thể

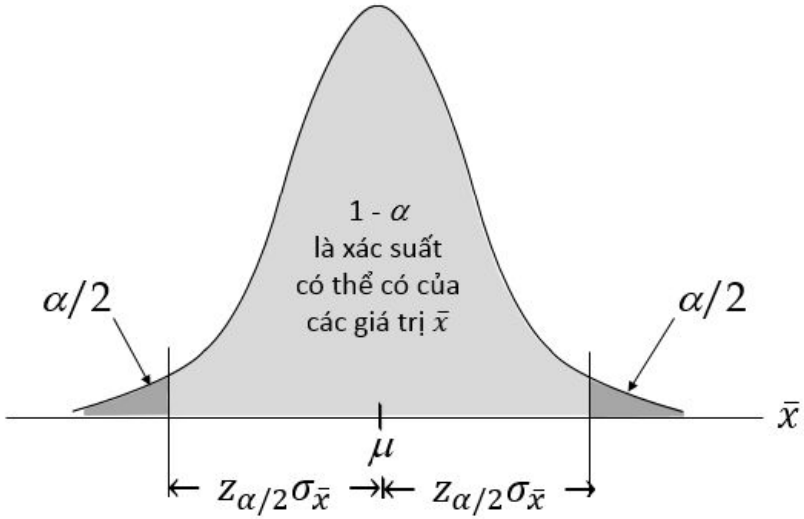

Neyman, J. (1937). Outline of a theory of statistical estimation based on the classical theory of probability. *Philosophical Transactions of the Royal Society of London. Series A, Mathematical and Physical Sciences, 236*(767), 333–380. https://doi.org/10.1098/rsta.1937.0005

Khoảng tin cậy - *CI*

$$CI = \bar{x} \pm z \cdot \frac{s}{\sqrt{n}}$$

$\bar{x}$: Giá trị trung bình mẫu (Điểm neo).

z : Giá trị z (Đại diện cho mức độ tin cậy mong muốn, VD: 1.96 cho 95%).

$\frac{s}{\sqrt{n}}$: Sai số chuẩn (Standard Error).

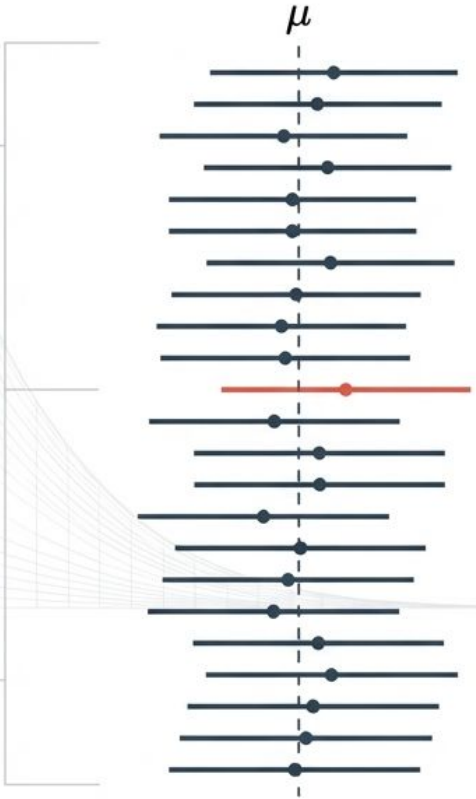

Kích thước mẫu (n) nằm ở mẫu số. Để thu hẹp khoảng tin cậy mà không giảm độ tin cậy, cách duy nhất là tăng kích thước mẫu.

NotebookLM

Ví dụ

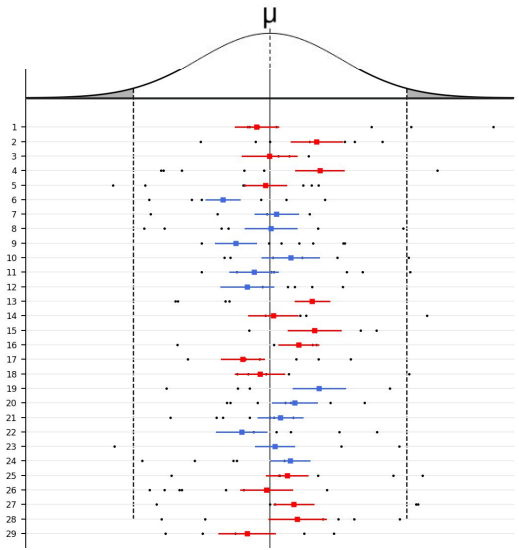

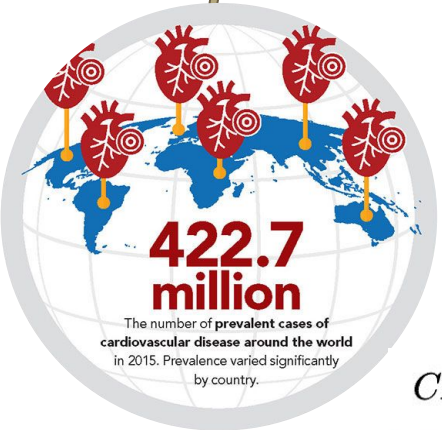

$$CI = \bar{x} \pm z \cdot \frac{s}{\sqrt{n}}$$

Mean value

Lower/Upper limit

z-value for the confidence level

Standard deviation

Sample size

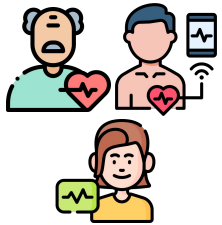

Heart Rate

n = 918

X = 136.809

sd = 25.460

Neyman, J. (1937). Outline of a theory of statistical estimation based on the classical theory of probability. *Philosophical Transactions of the Royal Society of London. Series A, Mathematical and Physical Sciences, 236*(767), 333–380. https://doi.org/10.1098/rsta.1937.0005

Khoảng tin cậy - *CI*

Ví dụ: Tính hệ số tin cậy của MaxHR (CI95%) với Cholesterol

```
n = 918
xbar = 136.809
s = 25.460
se <- s / sqrt(n)

alpha <- 0.05
tcrit <- qt(1 - alpha/2, df = n - 1)
ME <- tcrit * se

CI_lower <- xbar - ME
CI_upper <- xbar + ME
```

```
> n = 125591
  mean = 136.809368191721
  sd = 25.4603341382503
  se = 0.0718430629550688
  tcrit = 1.9599828737327
  CI_lower = 136.668557018733
  CI_upper = 136.95017936471
```

Function t-test

```
df <- read.csv("/content/Heart_Data.csv")
t.test(df$MaxHR, conf.level = 0.95)$conf.int
```

```
> 135.16020190543        138.458534478012
```

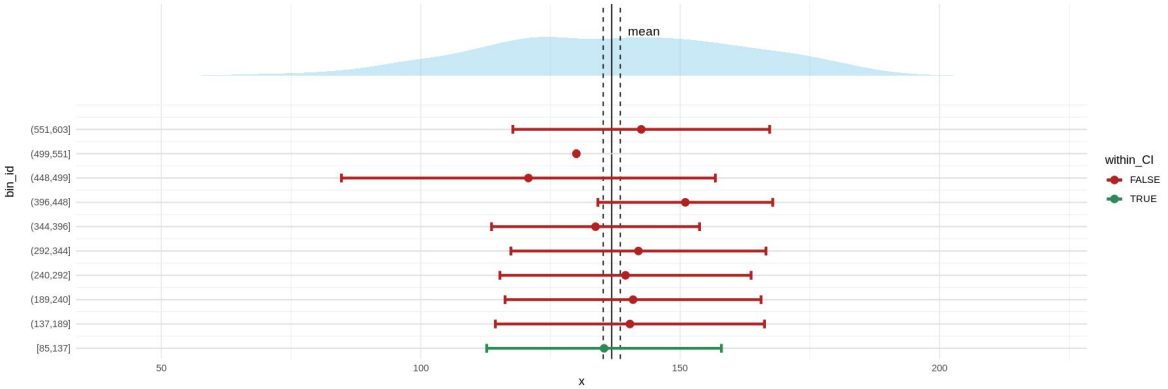

Hạn chế

- CI trả lời “ước lượng + độ chắc chắn”, **không trả lời trực tiếp** “có đáng kể về mặt sinh học/lâm sàng không”

- Kết quả không ổn định với tham số không tuyến tính hoặc mô hình phức tạp

Lưu ý:

- Với chênh lệch trung bình: nếu CI 95% không chứa 0 → thường tương ứng $p < 0.05$

- Với OR/RR: nếu CI 95% không chứa 1 → thường tương ứng $p < 0.05$